

TALLER PRÁCTICO · ESPECIALIZACIÓN EN CIENCIA DE DATOS · UNI

MLOps en la práctica

Del notebook a producción

DÍA 1 · Del notebook al modelo gestionado

Reproducibilidad · Experiment tracking · Model Registry

Jordan King Rodriguez Mallqui – Doctorando en Ciencias e Ingeniería Estadística



“Funciona en mi notebook” no es un producto

87%

de los proyectos de ML nunca llegan a
producción

VentureBeat / Redapt, cifra citada en la industria



“El AUC me salió distinto hoy”

Nadie fijó semillas ni versiones: el resultado no se puede reproducir



“¿Cuál era el modelo bueno?”

Los experimentos viven en la memoria (o en un Excel heroico)



“En producción predice cualquier cosa”

El preprocesamiento de producción no es el de entrenamiento



“El modelo se malogró solo”

Nadie monitorea los datos: el mundo cambió y el modelo no

MLOps: el ciclo de vida completo del modelo

Ingeniería de software + ciencia de datos + operaciones. El modelo no es el fin: es una pieza de un sistema vivo.



En estas 8 horas recorreremos el ciclo COMPLETO con un solo caso real. No veremos 20 herramientas por encima: dominaremos un stack mínimo y gratuito que puedes instalar en tu empresa mañana.

AndesTel: predecir la fuga de clientes (churn)

Telco peruana ficticia con datos sintéticos realistas. Un solo caso que evoluciona durante todo el taller: de notebook desordenado a servicio monitoreado en producción.



2.4 M

clientes activos



14%

se fuga cada trimestre



S/ 540

cuesta perder un cliente (año)



S/ 15

cuesta retenerlo a tiempo

LA MISIÓN

Predecir qué clientes están por irse para que el call center los retenga a tiempo — y llevar ese modelo a producción sin que muera en el intento.

EL DATASET

7,560 clientes · 13 variables (plan, antigüedad, reclamos, caídas de red, pagos...) — con nulos y duplicados a propósito, como en la vida real. Y un segundo lote “de 2026” que guardamos para el final...

5 labs, un caso, el ciclo completo

L1

Proyecto reproducible seeds · pipeline sklearn · contrato de datos

HOY

L2

Experiment tracking MLflow: 12 modelos sin perderse

HOY

L3

Registry + Serving champion/challenger · API FastAPI

HOY + MAÑANA

L4

Docker + CI/CD GitHub Actions con repo plantilla

MAÑANA

L5

Monitoreo y drift Evidently: el modelo se degrada solo

MAÑANA



TE LLEVAS

- 4 notebooks resueltos
- Repo plantilla con CI/CD
- Checklist de madurez MLOps
- Proyecto integrador para tu trabajo

Reglas del juego (taller 100% virtual)



Google Colab, cero instalación

Todo corre en el navegador. ¿Prefieres local? requirements.txt en el repo del taller.



Un solo repo con todo

Notebooks, datos y plantilla. Enlace en el chat — ábrelo AHORA y deja el Lab 1 cargando.



Salas de 5 para los retos

Cada lab: 15-20 min guiados + retos en salas. Nadie se queda atascado más de 3 min: pregunta.



Dos velocidades

Retos marcados “todos” y “avanzado”. Si terminas antes, el reto avanzado te espera.



Cámaras opcionales, chat obligatorio

Respondo el chat en cada pausa. Errores en pantalla = aprendizaje para todos.



Pausa de 10 min a mitad de sesión

4 horas rinden si las cortamos bien.

L1

LAB 1 · 60 MIN

Del notebook caótico al proyecto reproducible

OBJETIVO convertir el “modelo del practicante” en un pipeline reproducible que tolera datos sucios.

EN ESTE LAB

- Autopsia de un anti-ejemplo real: encuentra los 6 problemas
- Regla de oro: código + datos + config = mismo resultado, siempre
- Contrato de datos: validar a la entrada, fallar ruidosamente
- Pipeline de sklearn: imputación y encoding DENTRO del modelo
- Métricas honestas con 14% de churn (spoiler: accuracy no)
- Umbral de decisión: S/ 540 vs S/ 15 — negocio decide, no el default



CUADERNO
nb1_proyecto_
reproducible.ipynb



¿VAS RÁPIDO?
Feature nueva con FunctionTransformer,
dentro del pipeline (Reto 4)

El artefacto desplegable es el pipeline completo

✗ LO FRÁGIL

Preprocesar en el notebook con pandas → entrenar → guardar SOLO el clasificador.

En producción alguien re-implementa la limpieza “igualita”... y nunca es igualita: training-serving skew.

✓ LO ROBUSTO

Imputación + encoding + modelo en UN Pipeline de sklearn, entrenado y guardado como una sola pieza.

Producción manda datos crudos; el pipeline hace todo. Un solo camino, cero desviación.



L2

LAB 2 · 75 MIN

Experiment tracking con MLflow

OBJETIVO que ningún experimento vuelva a perderse: parámetros, métricas, artefactos y modelos, registrados solos.

EN ESTE LAB

- Anatomía de un run: params, métricas, artefactos, tags, modelo
- Barrido real: 12 configuraciones × 3 familias de modelos
- La UI de MLflow: comparar, filtrar, ordenar (demo + proxy en Colab)
- mlflow.search_runs: tabla de líderes por código
- Elegir campeón con criterio EXPLÍCITO y auditable
- Tu run compite: agrega tu configuración al barrido



CUADERNO
nb2_mlflow_
tracking.ipynb



¿VAS RÁPIDO?

autolog() y gráfico AUC vs tiempo registrado
como artefacto (Retos 3-4)

Elegir modelo es una decisión, no una corazonada

NUESTRO CRITERIO (documentado y repetible)

1

AUC dentro del top

candidatos a ± 0.01 del mejor — empate técnico

2

Mayor recall gana

el negocio prefiere detectar fugas (S/ 540 vs S/ 15)

3

Ante empate, el más simple

menos costo de mantener, más fácil de explicar

El criterio se negocia con negocio UNA vez y queda escrito. La próxima selección no es una reunión de 2 horas: es una celda de código.




TRAMPA FRECUENTE

Optimizar la 4ª cifra decimal del AUC mientras el modelo compara contra datos de hace 8 meses.

El mejor modelo del mundo con datos viejos pierde contra un modelo decente re-entrenado a tiempo.

Model Registry: del run ganador al modelo oficial

El tracking responde “¿qué probamos?”. El Registry responde “¿cuál es EL modelo, qué versión sirve producción y quién aprobó el cambio?”



L3

LAB 3 · 40 MIN

Model Registry (parte A)

OBJETIVO registrar el campeón del barrido como modelo oficial versionado y promoverlo con alias.

EN ESTE LAB

- Registrar el run campeón bajo el nombre “churn-andestel”
- Asignar el alias @champion + documentar la decisión
- Cargar el modelo por alias: models:/churn-andestel@champion
- Reto: registrar una variante como @challenger
- Dejar todo listo para servirlo mañana por API



CUADERNO
nb3_registry_
serving.ipynb (Parte A)



¿VAS RÁPIDO?
Simula un rollback: mueve @champion a la versión anterior y verifica qué carga producción

Hoy: el modelo dejó de vivir en tu memoria



Reproducible — misma config → mismo resultado, en cualquier máquina



Rastreado — 12+ experimentos comparables en segundos, con criterio de selección explícito



Versionado y promovible — churn-andestel v1 @champion, listo para producción



PARA MAÑANA (15 MIN, EN SERIO)

1. Crea tu cuenta de GitHub si no tienes (github.com — gratis).
2. Descarga la plantilla del repo del taller y hojear su README.
3. **NO cierras tu Colab del Lab 3 sin descargar mlflow.db (te lo pedirá el Lab de mañana).**